

Práctica No. 3

Reconocimiento de Patrones en Visión por Computadora: Clasificación de Objetos Utilizando el Clasificador de Bayes

Aarón Ernesto Alvarez Gómez *

Universidad Autónoma Metropolitana, Unidad Azcapotzalco. Ciudad de México.

18 de julio de 2025

Resumen

En esta práctica se trabajó con un conjunto de 100 imágenes, distribuidas en cinco clases: alcayata, armella, cola de pato, rondana y tornillo. Inicialmente, todas las imágenes fueron convertidas a vectores fila y organizadas en una matriz, en la que cada fila representaba una imagen individual. A partir de esta representación, se calcularon estadísticas básicas como la media, la varianza y la desviación estándar, así como medidas adicionales como la entropía y la energía de cada imagen.

Con estas características, se entrenó un clasificador de Bayes, utilizando un 80 % del conjunto de datos para entrenamiento y el 20 % restante para evaluación, obteniendo una precisión del 88 %.

Posteriormente, se aplicó un tratamiento de segmentación a las imágenes, el cual consistió en operaciones de preprocesamiento (ajuste de contraste, conversión a escala de grises) y umbralización (manual o automática), con el objetivo de aislar el objeto principal de cada imagen y eliminar el fondo. Algunas clases incluyeron además operaciones morfológicas para refinar la máscara. Tras este tratamiento, se repitió el proceso de extracción de características y clasificación, alcanzando una precisión del 96 %, lo cual evidencia una mejora significativa atribuible al procesamiento previo de las imágenes.

Palabras clave: Reconocimiento de patrones, Clasificador de Bayes, Clasificadores paramétricos, Visión por computadora, Segmentación de imágenes.

1. Introducción

El reconocimiento de patrones es una disciplina fundamental dentro del campo de la inteligencia artificial y la visión por computadora, cuyo objetivo principal es clasificar objetos o fenómenos a partir de características observables. Esta tarea es especialmente relevante cuando se trabaja con imágenes digitales, ya que permite automatizar procesos de identificación y clasificación en diversos contextos, como el control de calidad, la robótica o el análisis biométrico.

En esta práctica, se aborda la aplicación del reconocimiento de patrones sobre un conjunto de imágenes correspondientes a cinco tipos de objetos: tornillo, rondana, alcayata, armella y cola de pato. El objetivo es diseñar un sistema de clasificación basado en un modelo estadístico, específicamente el clasificador de Bayes, el cual es representativo de los clasificadores paramétricos por su fundamentación probabilística y su eficiencia en problemas donde la distribución de las clases puede ser modelada adecuadamente.

2. Marco teórico.

Clasificadores y clasificadores paramétricos

Un *clasificador* es una función que asigna una observación x a una clase C_k dentro de un conjunto finito de clases. El objetivo es minimizar los errores de clasificación, es decir, reducir la probabilidad de asignar una clase incorrecta.

De acuerdo con Fukunaga [1], un *clasificador paramétrico* asume que los datos provienen de una distribución de probabilidad con forma conocida (por ejem-

*al2249804679@azc.uam.mx

plo, una distribución normal) y que esta puede ser descrita por un conjunto finito de parámetros. Estos parámetros se estiman a partir de un conjunto de entrenamiento. Este tipo de clasificadores es eficiente cuando la suposición sobre la forma de la distribución es válida.

Theodoridis y Koutroumbas [2] refuerzan esta definición, destacando que los clasificadores paramétricos requieren menos información que los no paramétricos, lo que los hace adecuados para problemas con alta dimensionalidad. Bishop [3] agrega que estos clasificadores permiten una interpretación estadística sólida y se integran naturalmente dentro del marco probabilístico del aprendizaje supervisado.

Clasificador de Bayes

El *clasificador de Bayes* es un ejemplo fundamental de clasificador paramétrico. Su formulación se basa en el teorema de Bayes:

$$P(C_k | \mathbf{x}) = \frac{P(\mathbf{x} | C_k)P(C_k)}{P(\mathbf{x})} \quad (1)$$

donde:

- $P(C_k | \mathbf{x})$ es la probabilidad posterior de que la observación \mathbf{x} pertenezca a la clase C_k ,
- $P(\mathbf{x} | C_k)$ es la verosimilitud de los datos dada la clase,
- $P(C_k)$ es la probabilidad a priori de la clase,
- $P(\mathbf{x})$ es la probabilidad total de los datos (evidencia).

La decisión final se toma asignando a \mathbf{x} la clase con la probabilidad posterior más alta:

$$\hat{C} = \arg \max_{C_k} P(C_k | \mathbf{x}) \quad (2)$$

3. Desarrollo

Preparación y representación de datos

Se trabajó con una base de datos compuesta por 100 imágenes en formato .bmp, organizadas en cinco clases distintas: tornillo, rondana, alcayata, armella y cola de pato. Para cada clase se dispusieron 20 imágenes.

a) Conversión de imágenes en vectores

Cada imagen fue redimensionada a una resolución fija de 32x32 píxeles para uniformar el tamaño y facilitar el procesamiento. Posteriormente, la imagen fue convertida en una única fila utilizando la función reshape, obteniendo un vector de 1024 elementos (32x32). Estos vectores se almacenaron en una matriz por clase, de modo que se obtuvo una matriz de 20x1024 por cada clase, donde cada fila representa una imagen individual.

b) Cálculo de estadísticas básicas

A cada imagen (representada como vector) se le calcularon las siguientes estadísticas:

- Media: nivel promedio de intensidad.
- Varianza: grado de dispersión de los valores.
- Desviación estándar: medida de la variabilidad o dispersión respecto a la media.
- Los valores se calcularon por clase como el promedio de las estadísticas individuales de sus 20 imágenes.

c) Visualización y análisis de estadísticas

Se generaron gráficos para visualizar los valores de media, varianza y desviación estándar por clase. Esto permitió observar diferencias en la distribución de intensidades entre clases. Por ejemplo, se identificaron clases con mayor homogeneidad (baja varianza) o con valores promedio significativamente más altos.

d) Energía y entropía por clase

Se calcularon dos medidas adicionales:

- Energía: se definió como la suma de los cuadrados de los valores de los vectores de cada imagen. Esta métrica da una idea de la magnitud total de la señal.
- Entropía: medida del grado de desorden o complejidad de la imagen, basada en el histograma de intensidades normalizado.

Ambas métricas se calcularon para cada imagen y posteriormente se promediaron por clase. Los resultados fueron representados gráficamente, lo cual permitió identificar qué clases presentan mayor complejidad o contenido de información.

e) Clasificación con Bayes

Se utilizó el clasificador de Bayes para evaluar la capacidad discriminativa de las características extraídas. Para ello, se construyó un vector de características para cada imagen compuesto por:

- Media,
- Varianza,
- Desviación estándar,
- Energía normalizada,
- Entropía.

Se dividieron los datos en un 80 % para entrenamiento (15 imágenes por clase) y 20 % para prueba (5 imágenes por clase). Utilizando la función *fitcdiscr* de MATLAB, se entrenó un modelo de discriminante lineal (LDA), y se evaluó su desempeño con una matriz de confusión. La precisión obtenida fue del 88 %.

Segmentación y tratamiento previo

Con el objetivo de mejorar la calidad de las características extraídas y, por ende, el desempeño del clasificador, se aplicó un proceso de segmentación para aislar el objeto de interés de cada imagen, eliminando el fondo. Para ello, se definieron funciones específicas de segmentación por clase, generadas con la herramienta Image Segmenter de MATLAB. Estas funciones aplicaron:

- Ajuste de contraste (*imadjust*)
- Conversión a escala de grises
- Umbralización: Manual (umbral fijo) para alcayata, armella y tornillo. Automática (*imbinarize*) para cola de pato y rondana.
- Operaciones morfológicas (solo para alcayata), como apertura con un elemento estructurante cuadrado de tamaño 3.

El resultado fue una imagen binarizada con fondo negro y el objeto resaltado. Esta imagen segmentada fue nuevamente convertida en vector fila y se repitió el proceso de cálculo de características y clasificación. El clasificador de Bayes fue entrenado y evaluado con los vectores derivados de las imágenes tratadas, obteniéndose una precisión del 96 %, lo cual representa una mejora significativa respecto al caso sin tratamiento.

4. Experimentos

Para evaluar la efectividad del clasificador de Bayes en el reconocimiento de patrones aplicados a imágenes,

se llevaron a cabo dos experimentos : uno con imágenes sin tratamiento y otro posterior al proceso de segmentación. En ambos casos, se trabajó sobre el mismo conjunto de imágenes.

Primer experimento: imagenes sin tratamiento

En este primer escenario, se consideraron las imágenes en su forma original, únicamente reducidas a una resolución de 32×32 píxeles para uniformidad y eficiencia de procesamiento. Cada imagen fue transformada en un vector fila, resultando en una matriz por clase de 20×1024 elementos.

A partir de estos vectores, se calcularon las siguientes características para cada clase:

- Media,
- Varianza,
- Desviación estándar,
- Energía,
- Entropía.

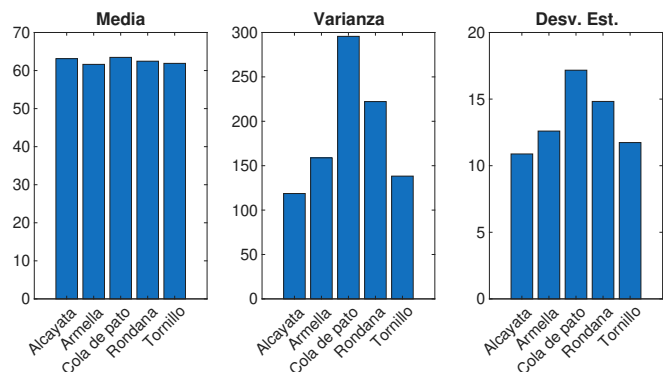


Figura 1: Estadísticos de las clases sin aplicar tratamiento a las imágenes.

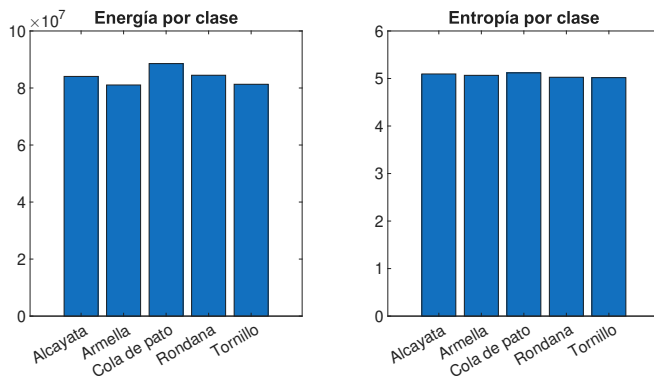


Figura 2: Entropía y energía de las clases sin aplicar tratamiento a las imágenes.

Con estas cinco características, se construyó un conjunto de datos para entrenar un clasificador de Bayes utilizando un modelo de discriminante lineal (*fitcdiscr* en MATLAB). La partición fue de 15 imágenes por clase para entrenamiento y 5 para prueba (es decir, un 80/20).

Resultados:

- Se obtuvo una precisión del 88 % en la clasificación.
- La matriz de confusión mostró que la mayoría de las clases fueron correctamente identificadas, aunque se observaron algunas confusiones entre clases visualmente similares.




Figura 3: Matriz de confusión de la clasificación mediante Bayes sin aplicar tratamiento a las imágenes.

Segundo experimento: imágenes segmentadas.

En el segundo experimento, se aplicó un tratamiento de segmentación a las imágenes con el propósito de eliminar el fondo y aislar el objeto de interés. Se utilizaron

funciones de segmentación específicas por clase, generadas con la herramienta Image Segmenter de MATLAB. Estas funciones aplicaban una combinación de:

- Ajuste de contraste (*imadjust*),
- Conversión a escala de grises,
- Umbralización (manual o automática según la clase),
- Operaciones morfológicas (en el caso de la clase “alcayata”).

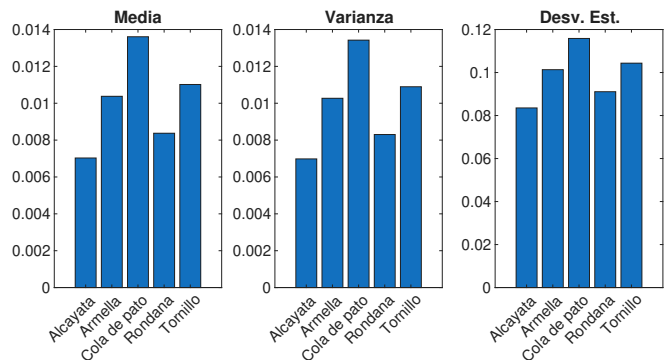


Figura 4: Estadísticos de las clases aplicando segmentación a las imágenes.

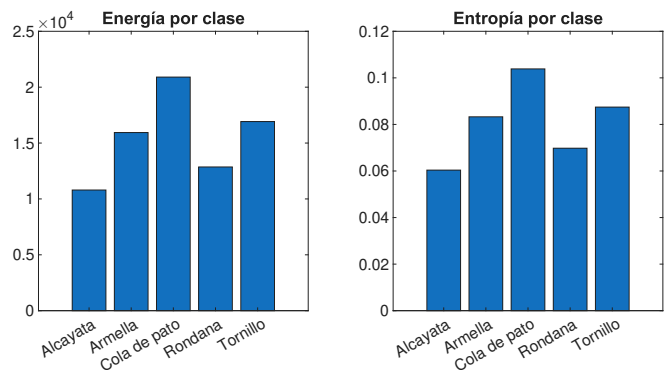


Figura 5: Entropía y energía de las clases aplicando segmentación a las imágenes.

Tras la segmentación, las imágenes fueron convertidas nuevamente en vectores y se repitió el proceso de extracción de características y clasificación.

Resultados:

- La precisión del clasificador aumentó a un 96%, lo que evidencia una mejora significativa gracias al preprocesamiento.
- La matriz de confusión mostró menor cantidad de errores de clasificación.

- Se redujo la variabilidad dentro de las clases, facilitando la separación entre clases distintas.

Matriz de Confusión

1	5				
2		5			
3			5		
4				5	
5		1			4
	1	2	3	4	5

Clase Verdadera

Clase Predicha

Figura 6: Matriz de confusión de la clasificación mediante Bayes de las clases aplicando segmentación a las imágenes.

5. Conclusiones

El presente trabajo permitió evaluar la eficacia del clasificador de Bayes en la tarea de reconocimiento de patrones aplicados a imágenes de cinco clases distintas de objetos, tanto con imágenes originales como con imágenes segmentadas.

Desempeño sin tratamiento

En la primera fase, se procesaron las imágenes sin aplicar segmentación. Los gráficos obtenidos muestran diferencias notables entre clases: por ejemplo, la clase Cola de pato presentó los valores más altos tanto en energía como en entropía, lo que sugiere mayor complejidad e intensidad en su contenido. Por otro lado, Alcayata y Rondana mostraron valores más bajos, lo cual puede reflejar menor variabilidad o patrones más simples.

El clasificador de Bayes, entrenado con estas características, alcanzó una precisión del 88 %, como se observa en la matriz de confusión correspondiente. Las principales confusiones ocurrieron entre Tornillo y Alcayata, así como entre Rondana y Armella, probablemente debido a similitudes visuales en regiones del fondo no segmentadas.

Desempeño con segmentación

Posteriormente, se aplicó una segmentación por clase

con el objetivo de aislar el objeto de interés y eliminar el fondo. Este tratamiento mejoró significativamente la homogeneidad de los datos por clase, lo que se reflejó en las gráficas:

Los valores de entropía se estabilizaron entre clases, lo que indica que el contenido informativo se centró en las formas del objeto.

La energía aumentó de manera considerable, debido a la presencia más clara y concentrada del objeto.

El clasificador, al trabajar con estos datos más limpios, logró una precisión del 96 %, reduciendo considerablemente los errores de predicción como se aprecia en la segunda matriz de confusión, donde la mayoría de las clases fueron correctamente clasificadas sin ambigüedad.

Referencias

- [1] K. Fukunaga, *Introduction to Statistical Pattern Recognition*, 2nd ed. Academic Press, 1990.
- [2] S. Theodoridis and K. Koutroumbas, *Pattern Recognition*, 4th ed. Academic Press, 2008.
- [3] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.